TP

10 de maio de 2026 17:45

AlphaZero

Resultados da execução em 09/05/2026

Treino do AlphaZero: 51 min.

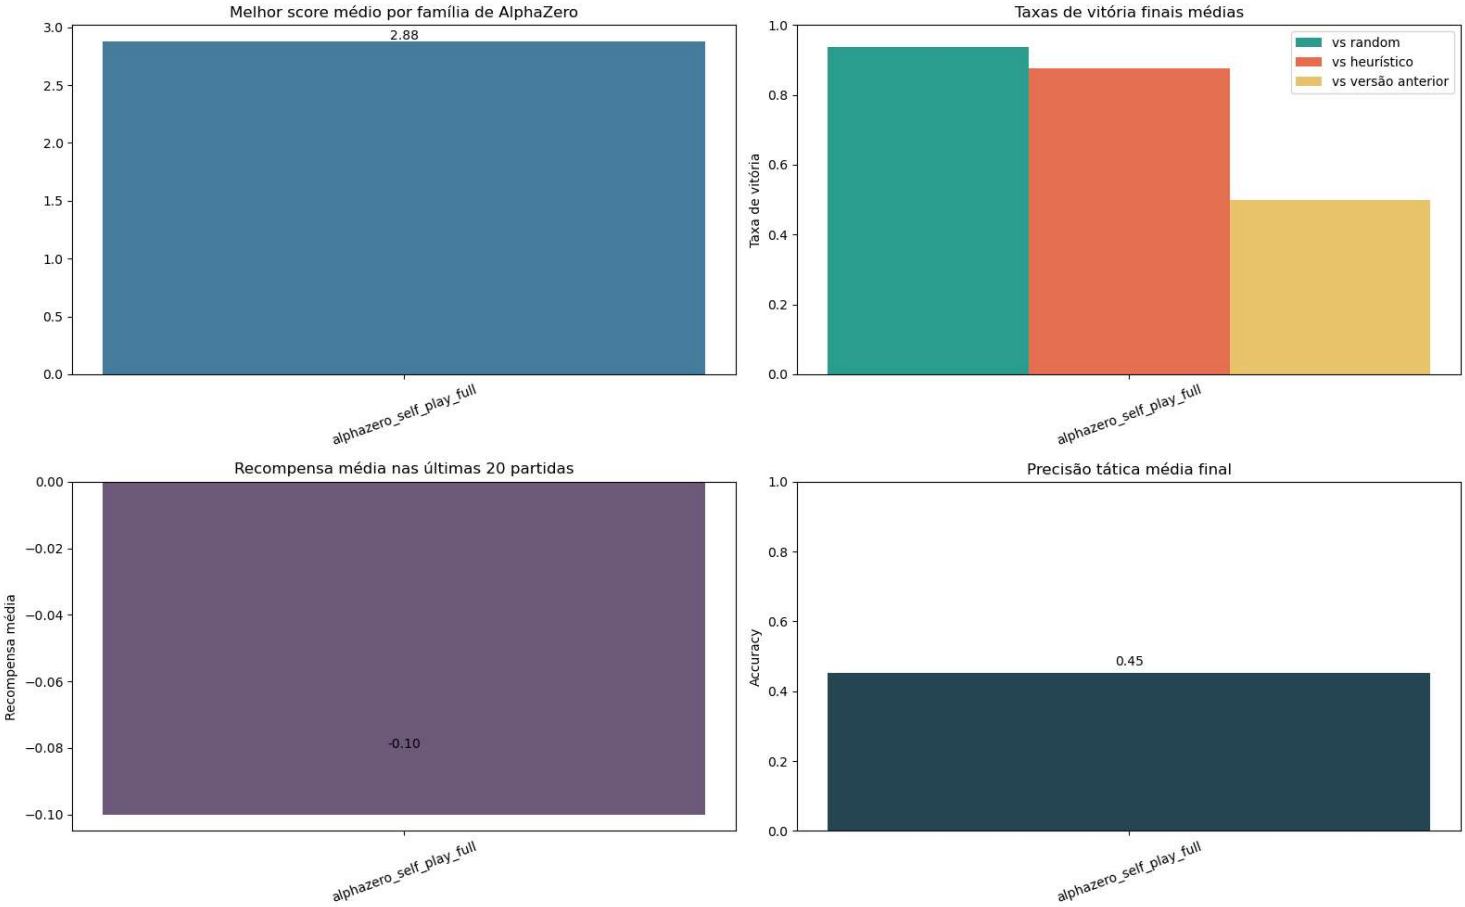

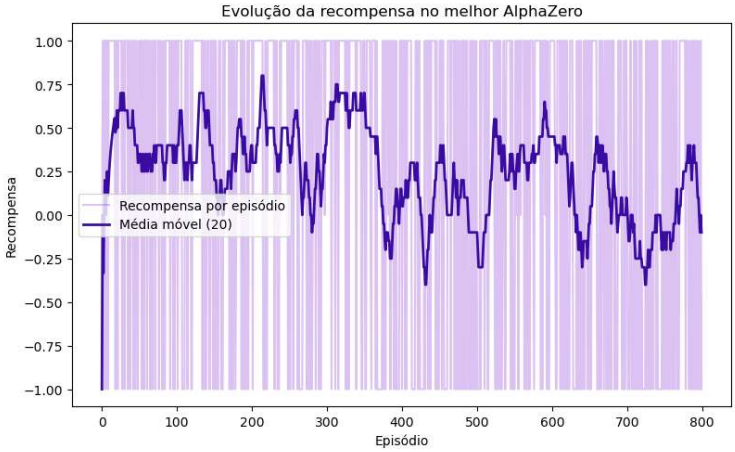

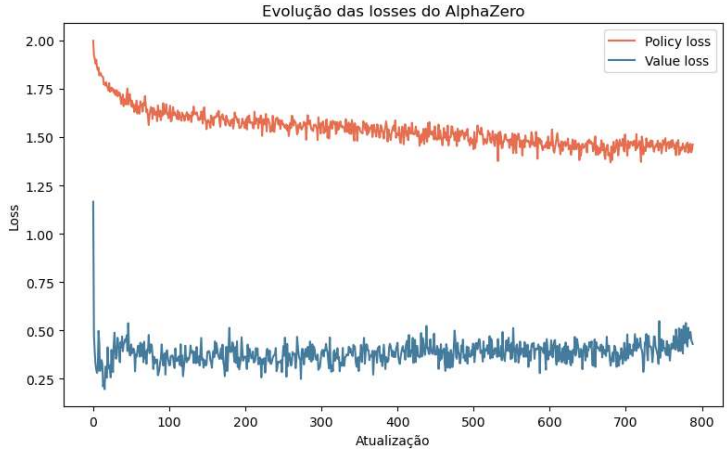

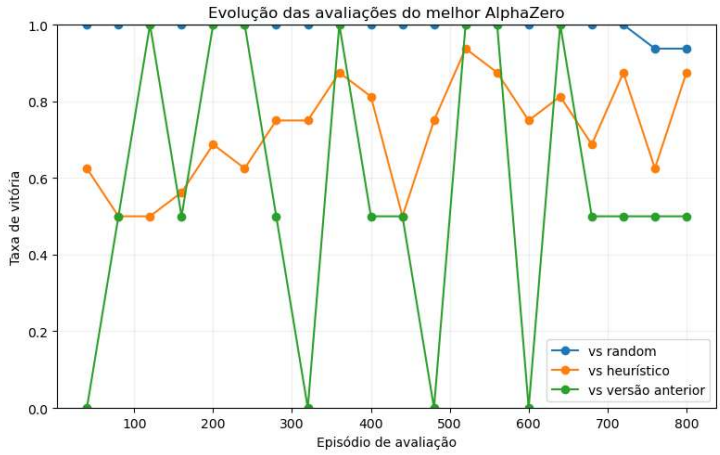

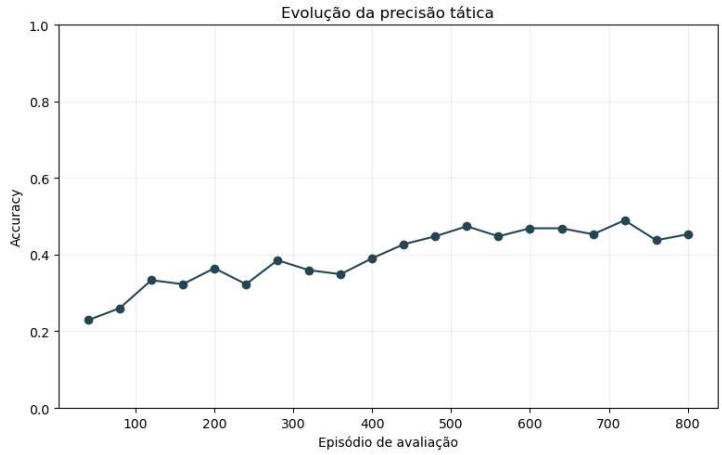

Resultados da execução em 10/05/2025

Treino do AlphaZero: 3h22m

```
{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 3.0,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.9166666666666666,
  'mean_last_vs_previous': 0.5,
  'mean_reward_last_20': -0.05,
  'mean_last_tactical_accuracy': 0.4375}}
```

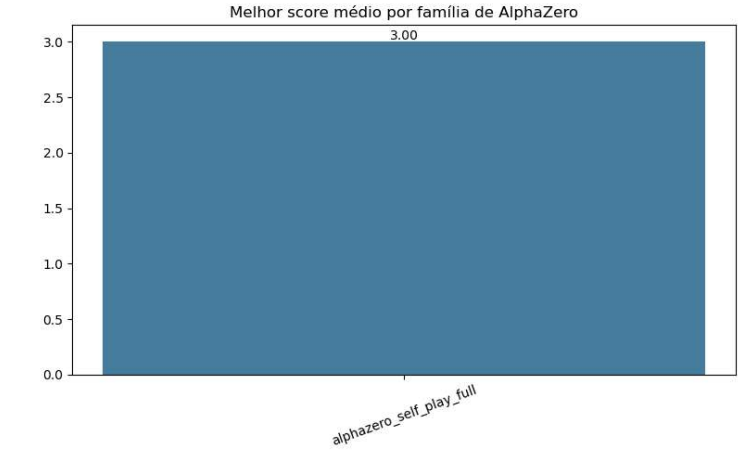
Melhor score médio por família de AlphaZero
3.00
alphazero_self_play_full

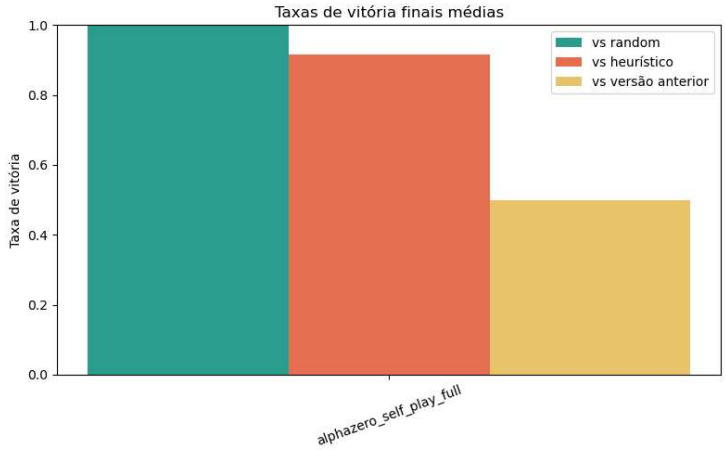
Taxas de vitória finais médias
vs random
vs heurístico
vs versão anterior
Taxa de vitória
alphazero_self_play_full

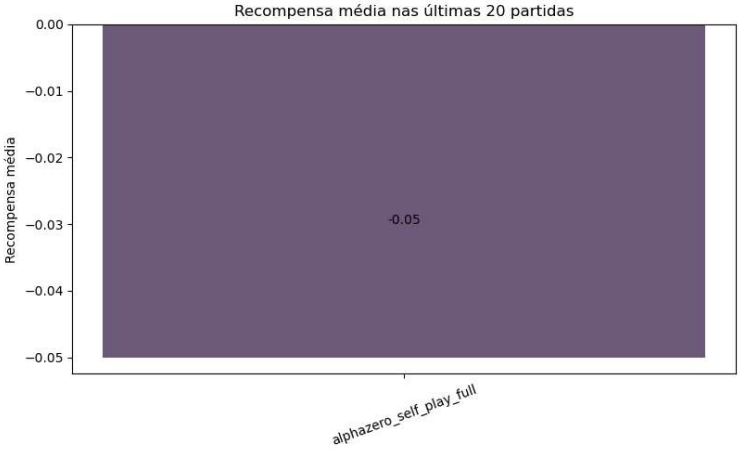
Recompensa média nas últimas 20 partidas
Recompensa média
-0.05
alphazero_self_play_full

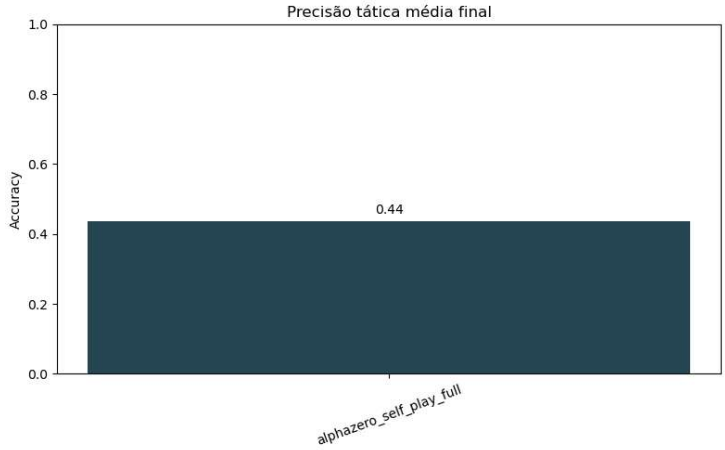
Precisão tática média final
Accuracy
0.44
alphazero_self_play_full

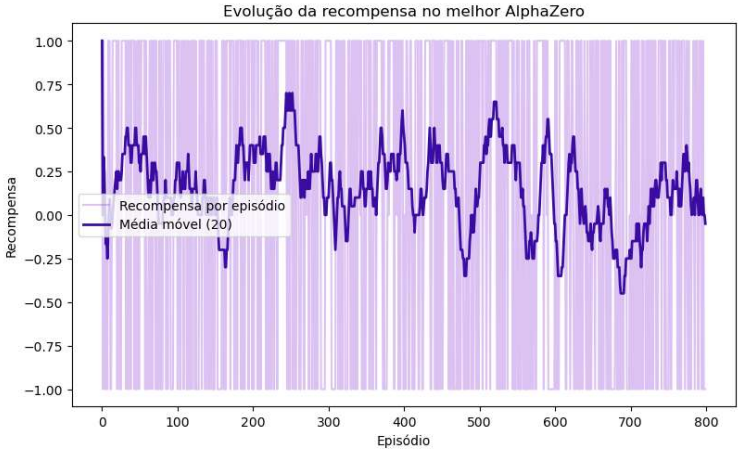
Evolução da recompensa no melhor AlphaZero
Recompensa
Recompensa por episódio
Média móvel (20)
Episódio

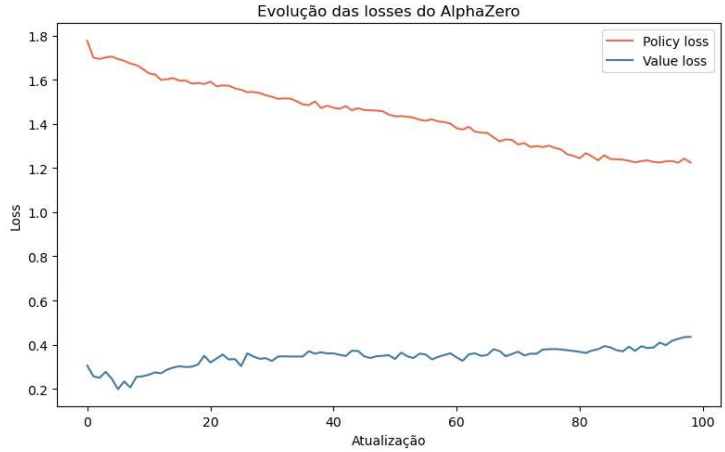
Evolução das losses do AlphaZero
Policy loss
Value loss
Loss
Atualização

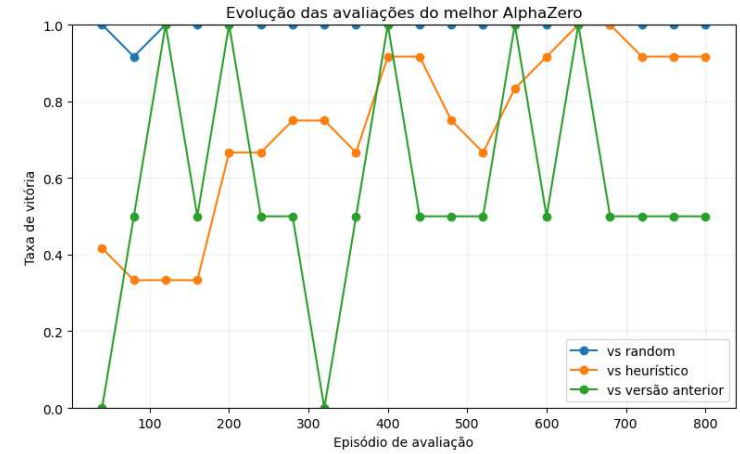
Evolução das avaliações do melhor AlphaZero
Taxa de vitória
vs random
vs heurístico
vs versão anterior
Episódio de avaliação

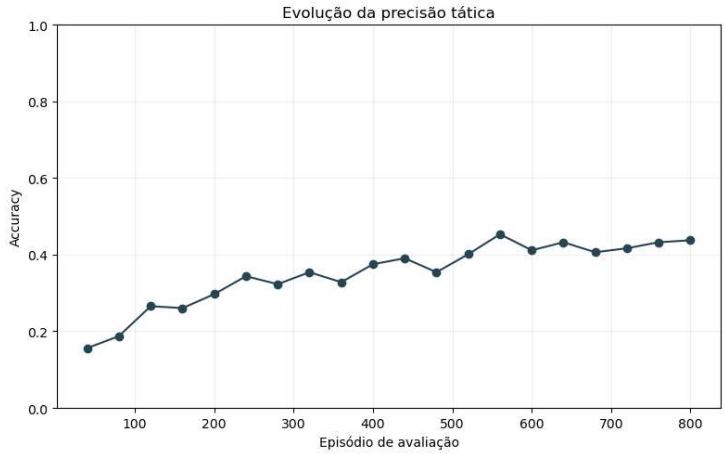
Evolução da precisão tática
Accuracy
Episódio de avaliação

Resumo Completo – Últimas 24h
Data: 2026-05-08 a 2026-05-11 | Foco: Estabilidade AlphaZero, paralelização e diagnóstico de deadlock

1. Alterações em config.yaml – Tuning para Estabilidade e Performance
AlphaZero:

- learning_rate: 0.001 → 0.0005 (reduz oscilação de recompensas)
- batch_size: 128 → 256 (melhor utilização de GPU)
- num_workers: 1 (default) → 8 (paralelismo de self-play)
- mcts_simulations: 48 → 64 (search mais forte)
- mcts_start_search_iter: 12 → 16 (search mais forte na fase inicial)
- mcts_max_search_iter: 48 → 64
- dirichlet_epsilon: 0.25 → 0.15 (menos ruído, targets menos voláteis)
- temperature: 1.25 → 1.0 (amostragem menos aleatória)
- temperature_drop_move: 8 → 6 (transição para greedy mais cedo)
- eval_games: 16 → 12 (mantém notebook responsivo)
- root_noise_each_move: true → false (ruído apenas na raiz)
- tactical_eval_examples: 64 → 96

Global:

- num_workers: 1 (comentado) → 8 (global CPU worker pool)

PPO:

- Adicionados campos de bootstrap e curriculum (antes ausentes):
  - `bootstrap_samples: 12000`
  - `bootstrap_batch_size: 256`
  - `bootstrap_epochs: 6`
  - `bootstrap_learning_rate: 0.0003`
  - `bootstrap_teacher_kind: "strong"`
  - `curriculum_profile: "tutorial"`
  - `self_play_min_episodes_before_early_stop: 60`
  - `self_play_early_stop_patience_evals: 2`

2. Alterações em config.py – Novos Campos PPO
Adicionados à classe `PPOConfig`:

- `bootstrap_samples: int = 0`
- `bootstrap_batch_size: int = 64`
- `bootstrap_epochs: int = 1`
- `bootstrap_learning_rate: float = 1e-4`
- `bootstrap_teacher_kind: str = "strong"`
- `curriculum_profile: str = "tutorial"`
- `freeze_feature_extractor_lessons: int = 0`
- `self_play_min_episodes_before_early_stop: int = 0`
- `self_play_early_stop_patience_evals: int = 2`
- Validações correspondentes para cada campo

3. Alterações em alphazero_training.py – Paralelização e Diagnóstico
Paralelização:

- Implementado ThreadPoolExecutor para batched self-play paralelo
- Helpers: _build_eval_network_from_state_dict, _build_eval_agent_from_state_dict, _generate_self_play_episode_from_state_dict
- Removida cópia cara list(replay_buffer) → sampling direto com rng.sample(deque, k)
- Adicionado device auto-resolution (config.device="auto" → cuda/cpu)
- Força MCTS workers para CPU (evita contention)

Últimas alterações (diagnóstico):

- Adicionado batch timeout monitor com concurrent.futures.wait() e FIRST_COMPLETED

- Timeout inicial: 120s por batch
- Se timeout: imprime `[BATCH TIMEOUT]` + thread stack dumps (mostra onde as threads estão bloqueadas)
- Estende timeout para 300s e continua monitorização
- Imports: sys, threading, traceback

4. Resumo de Impacto

Alteração	Objetivo
Tuning config.yaml AlphaZero	Estabilidade + qualidade
num_workers 1→8/4	Paralelismo self-play
PPO bootstrap fields	Fix TypeError
ThreadPoolExecutor paralelo	Velocidade treino
Batch timeout + stack dump	Diagnóstico deadlock

5. Próximos Passos
- Executar notebook e recolher logs (se houver stall, mostrará thread stacks)
- Baseado nos stacks, identificar causa exata do deadlock

Não houve nenhum bloqueio; o treino apenas ficou muito mais lento com ligeiras melhorias (ver gráficos acima).

Resultados da execução em 11/05/2025

Treino do AlphaZero: 71m

Remoção de ThreadPoolExecutor pois provocaca deadlock's. O Pytorch não é thread-safe.
A introdução de paralelismo apenas atrasou o processo de teste/tunning do modelo.

```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_
full_seed_42',
 'training_profile': 'full',
 'episodes': 800,
 'learning_rate': 0.0005,
 'batch_size': 256,
 'mcts_simulations': 64,
 'mcts_start_search_iter': 16,
 'mcts_max_search_iter': 64,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.0,
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 2}
```

Resultados

```
{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 3.0,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.9166666666666666,
  'mean_last_vs_previous': 1.0,
  'mean_reward_last_20': 0.3,
  'mean_last_tactical_accuracy': 0.3333333333333333}}
```

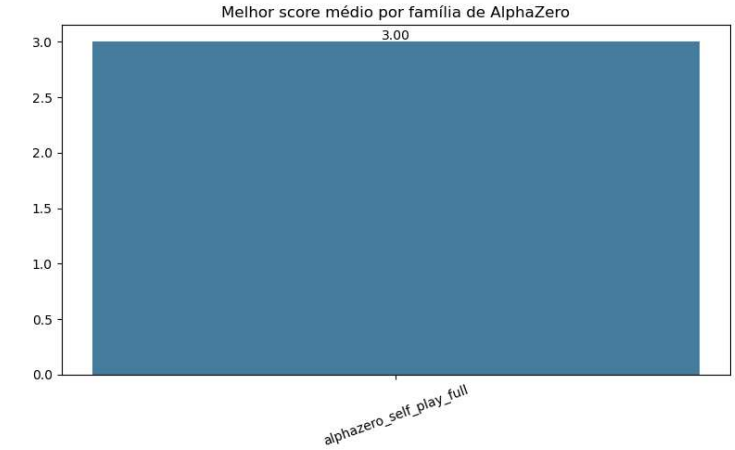
Melhor score médio por família de AlphaZero
3.00
alphazero_self_play_full

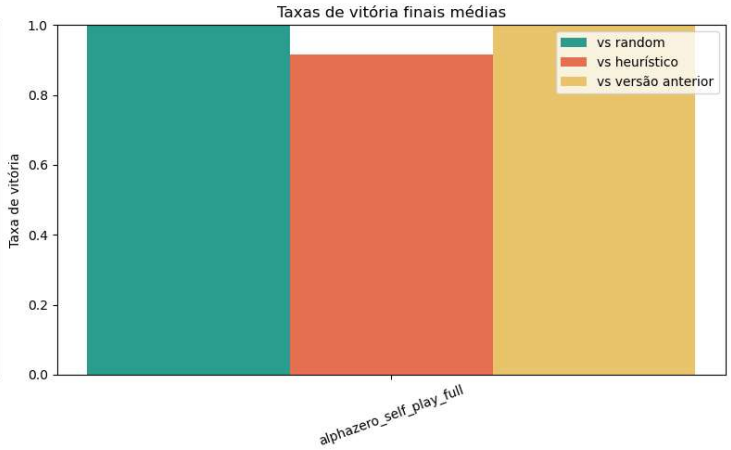
Taxas de vitória finais médias
vs random
vs heurístico
vs versão anterior
Taxa de vitória
alphazero_self_play_full

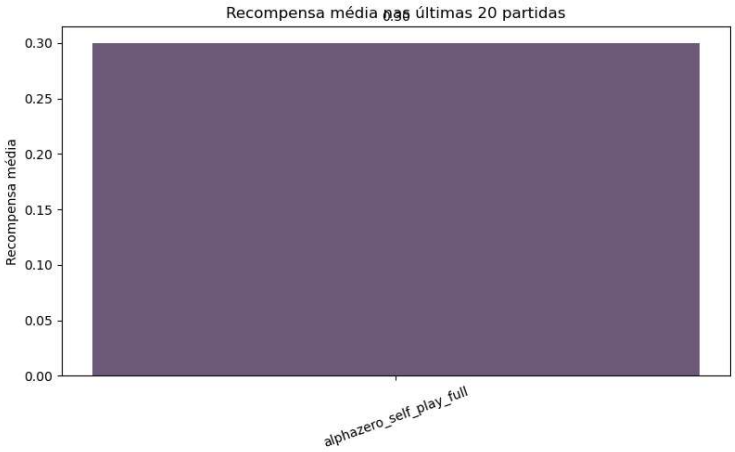
Recompensa média nas últimas 20 partidas
0.30
Recompensa média
alphazero_self_play_full

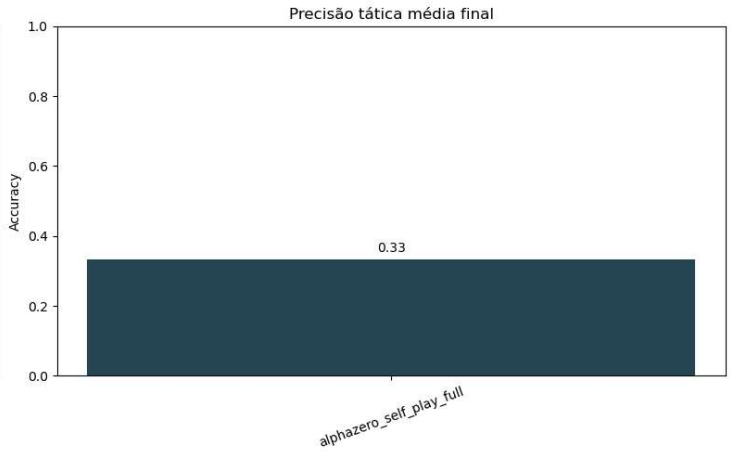
Precisão tática média final
0.33
Accuracy
alphazero_self_play_full

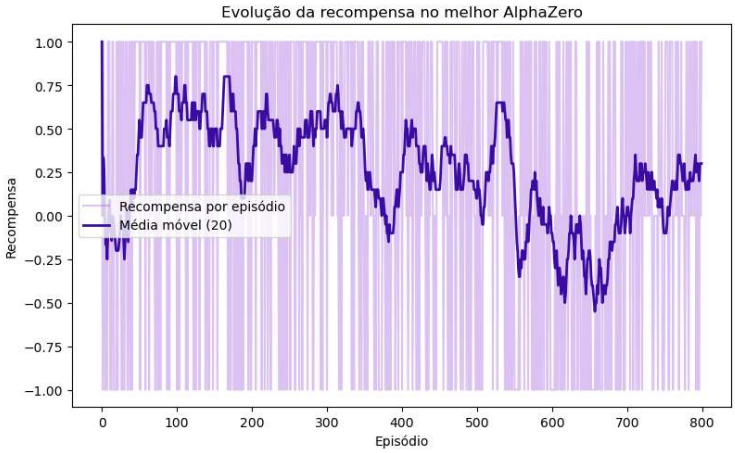
Evolução da recompensa no melhor AlphaZero
Recompensa por episódio
Média móvel (20)
Recompensa
Episódio

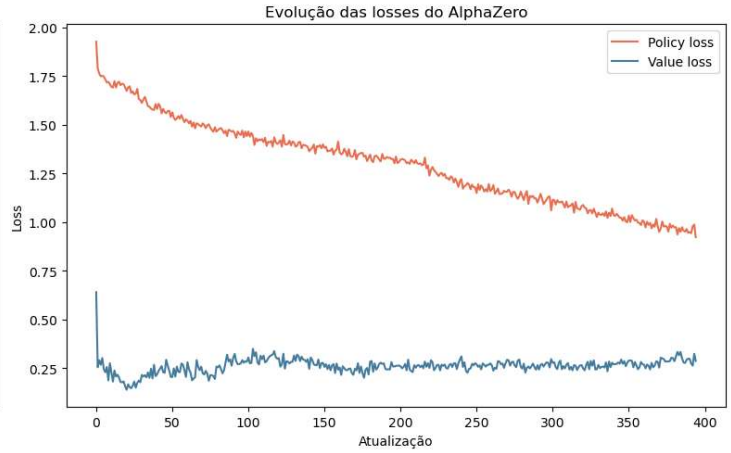
Evolução das losses do AlphaZero
Policy loss
Value loss
Loss
Atualização

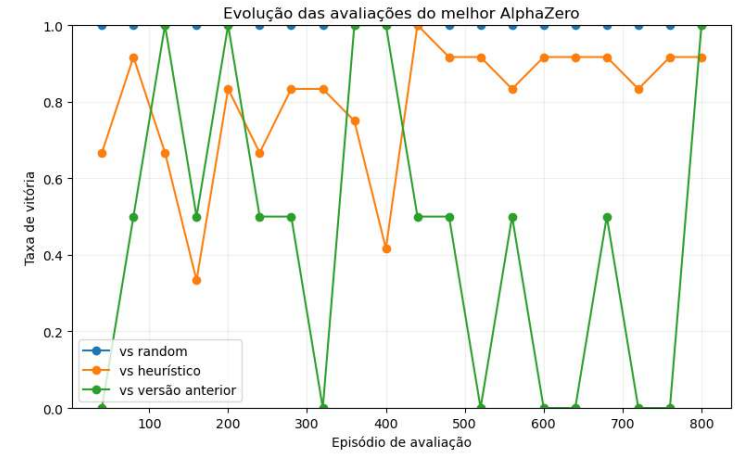
Evolução das avaliações do melhor AlphaZero
vs random
vs heurístico
vs versão anterior
Taxa de vitória
Episódio de avaliação

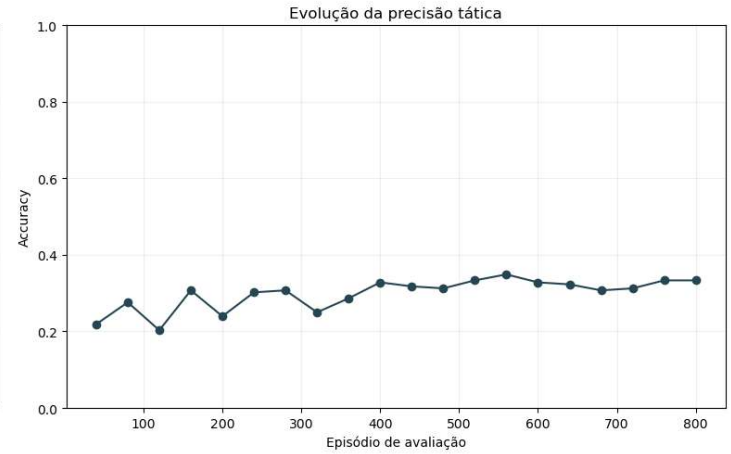
Evolução da precisão tática
Accuracy
Episódio de avaliação

Resultados da execução em 11/05/2025

Treino do AlphaZero: 66m


```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42',
 'training_profile': 'full',
 'episodes': 800,
 'learning_rate': 0.0005,
 'batch_size': 256,
 'mcts_simulations': 64,
 'mcts_start_search_iter': 16,
 'mcts_max_search_iter': 64,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.0,
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 4}

{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 2.833333333333333,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.6666666666666666,
  'mean_last_vs_previous': 1.0,
  'mean_reward_last_20': 0.0,
  'mean_last_tactical_accuracy': 0.375}}
```


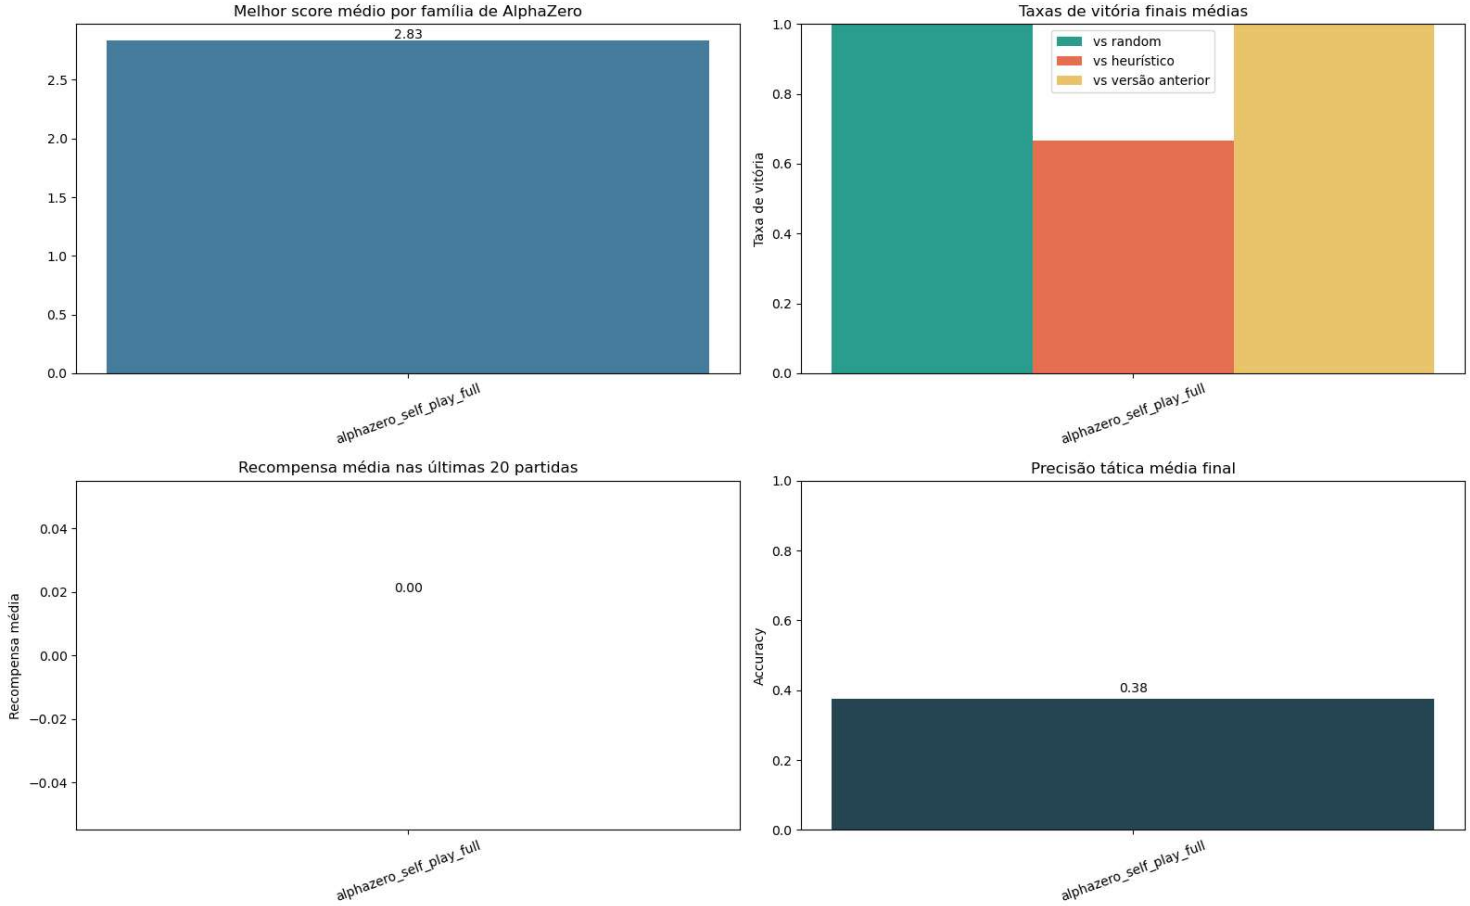

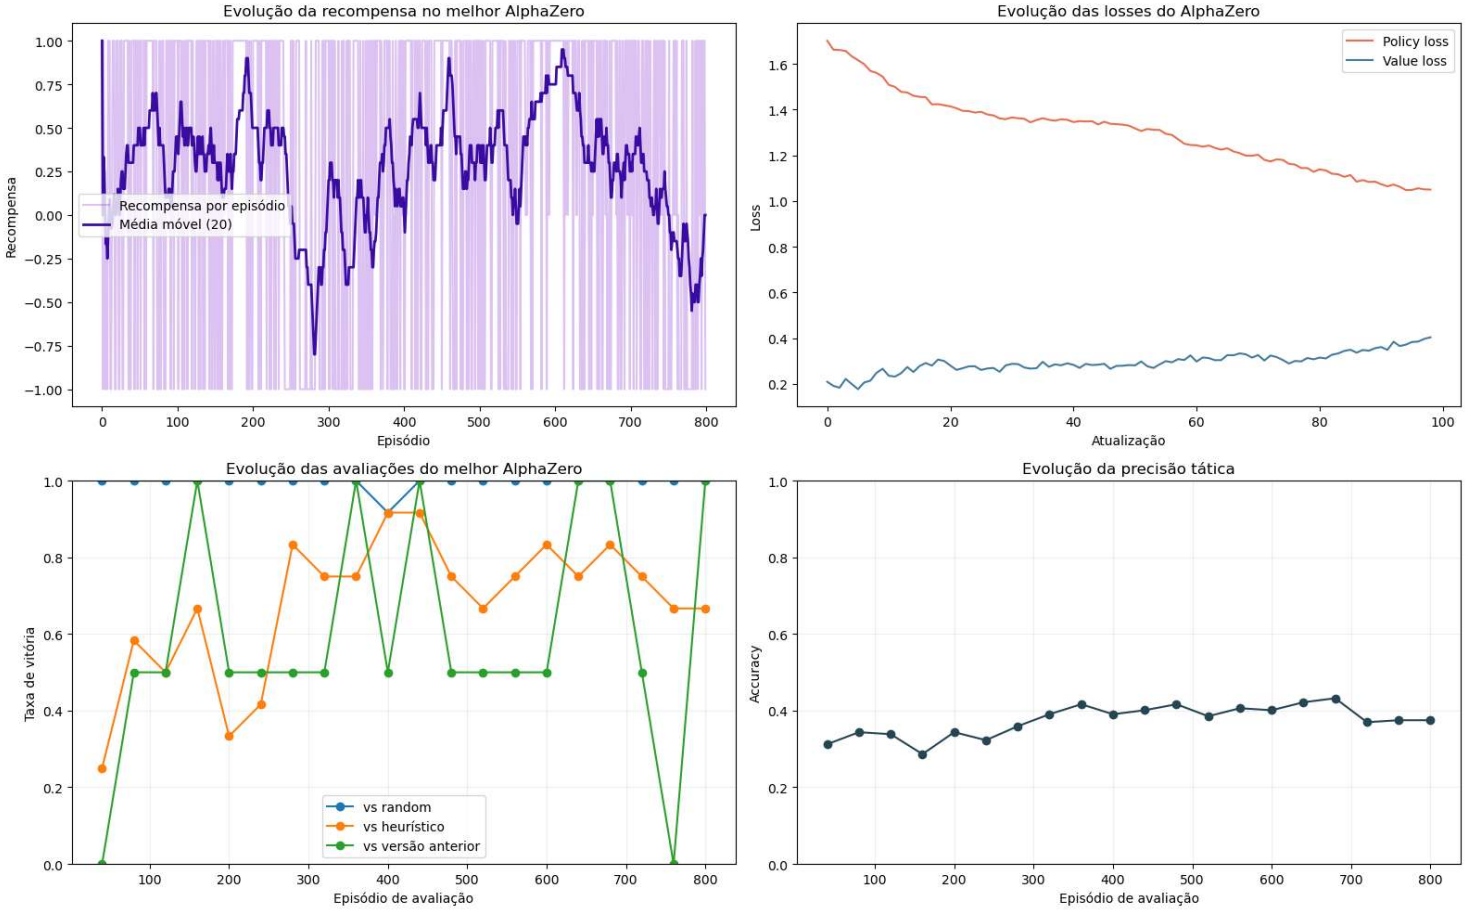

Resultados da execução em 11/05/2025

Treino do AlphaZero: 74m

```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42',
 'training_profile': 'full',
 'episodes': 800,
 'learning_rate': 0.0005,
 'batch_size': 256,
 'mcts_simulations': 64,
 'mcts_start_search_iter': 16,
 'mcts_max_search_iter': 64,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.0,
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 4}

{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 2.5833333333333335,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.5833333333333334,
  'mean_last_vs_previous': 1.0,
  'mean_reward_last_20': 0.2,
  'mean_last_tactical_accuracy': 0.3072916666666667}}
```

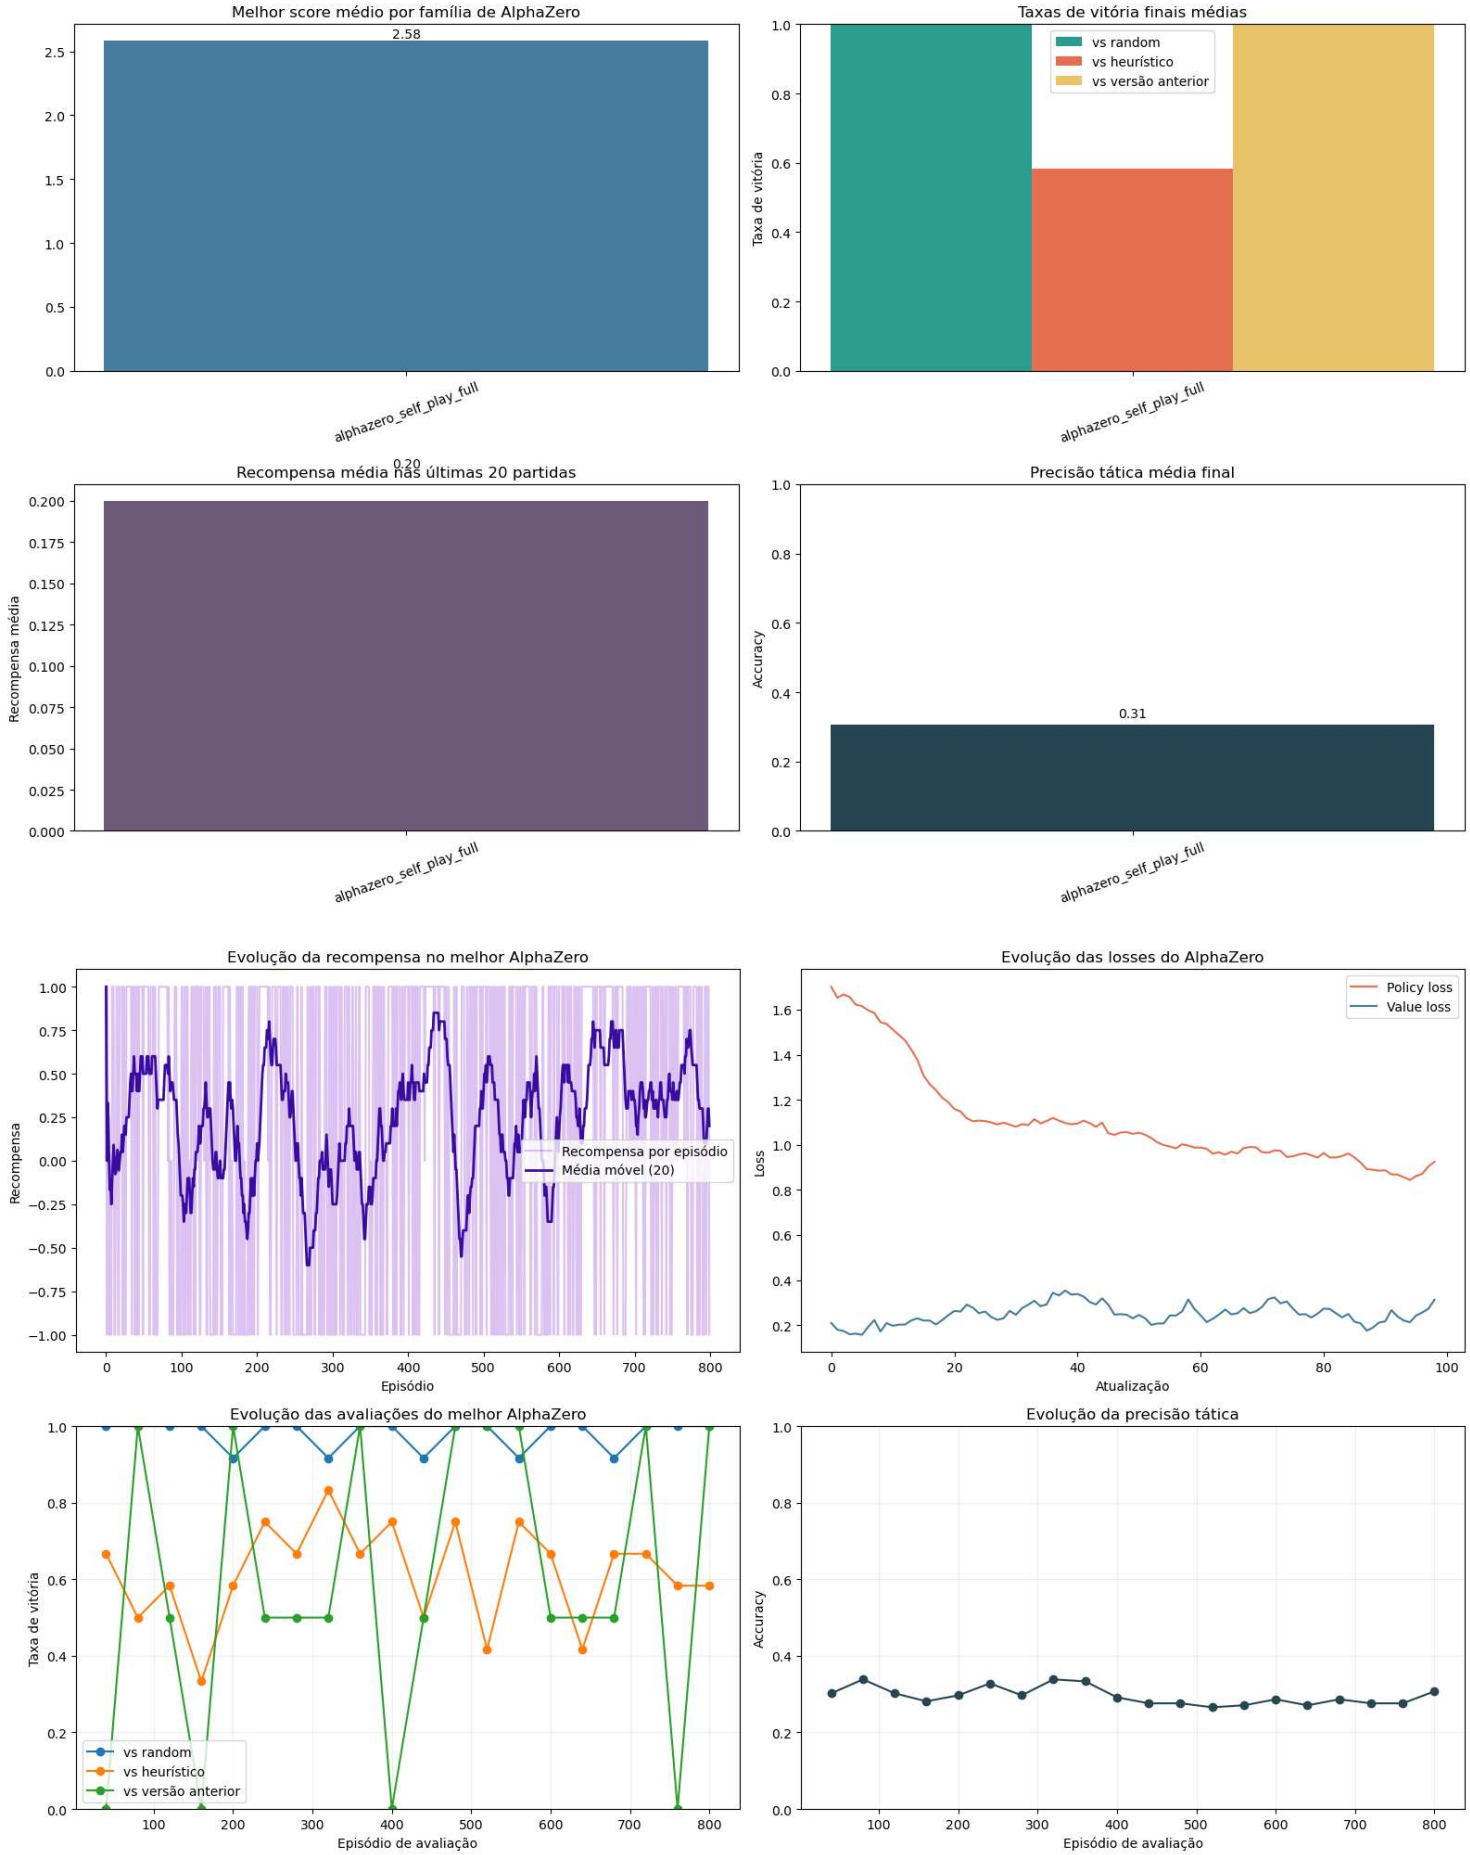

Últimas 10 Alterações

#	Descrição	Ficheiro	Impacto
1	Removido num_workers global	config.py, config.yaml	Limpeza de código redundante
2	Adicionado episodes_per_batch (substitui num_workers semântica)	config.py, alphazero_training.py	Batching explícito, semanticamente correto
5	Removidos imports não usados (sys, threading, traceback, etc.)	alphazero_training.py	Código mais limpo
6	Fixado device resolution bug (str(device) em AlphaZeroAgent)	alphazero_training.py	Bugfix: "auto" device crash
7	Aumentado updates_per_episode: 2 → 4	config.yaml	Mais updates por batch
8	Criado benchmark replay capacity (5000/10000/20000)	benchmark_alphazero_replay_capacity.py	Dados para otimização
9	Benchmark revelou 5000 é 25% mais rápido que 20000	-	Decisão de otimização, para validar se o treino executa mais rápido (o que não se verificou).
10	Alterado replay_capacity: 20000 → 5000	config.yaml	Estimativa 800ep: ~33min (vs 44min antes) - não se verificou redução no tempo de treino do modelo.

O que o replay_capacity faz

É o tamanho máximo do buffer de experiência de self-play. O treino amostra exemplos desse buffer para atualizar a rede.

- replay_capacity pequeno:
  - dados mais recentes
  - menor diversidade
  - maior risco de overfitting ao estado atual do agente
  - pode acelerar ou desacelerar dependendo da implementação e da aleatoriedade do treino
- replay_capacity grande:
  - mais diversidade histórica
  - exemplos mais “antigos” entram nas updates
  - treino potencialmente mais estável, mas pode ficar mais lento e menos “agressivo” a adaptar-se

---

Resultados da execução em 12/05/2025

Treino do AlphaZero: 74m

Replay_capacity = 10000

```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42',
 'training_profile': 'full',
 'episodes': 800,
 'learning_rate': 0.0005,
 'batch_size': 256,
 'mcts_simulations': 64,
 'mcts_start_search_iter': 16,
 'mcts_max_search_iter': 64,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.0,
```

```
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 4}

{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 2.833333333333333,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.9166666666666666,
  'mean_last_vs_previous': 0.5,
  'mean_reward_last_20': -0.5,
  'mean_last_tactical_accuracy': 0.34375}}
```


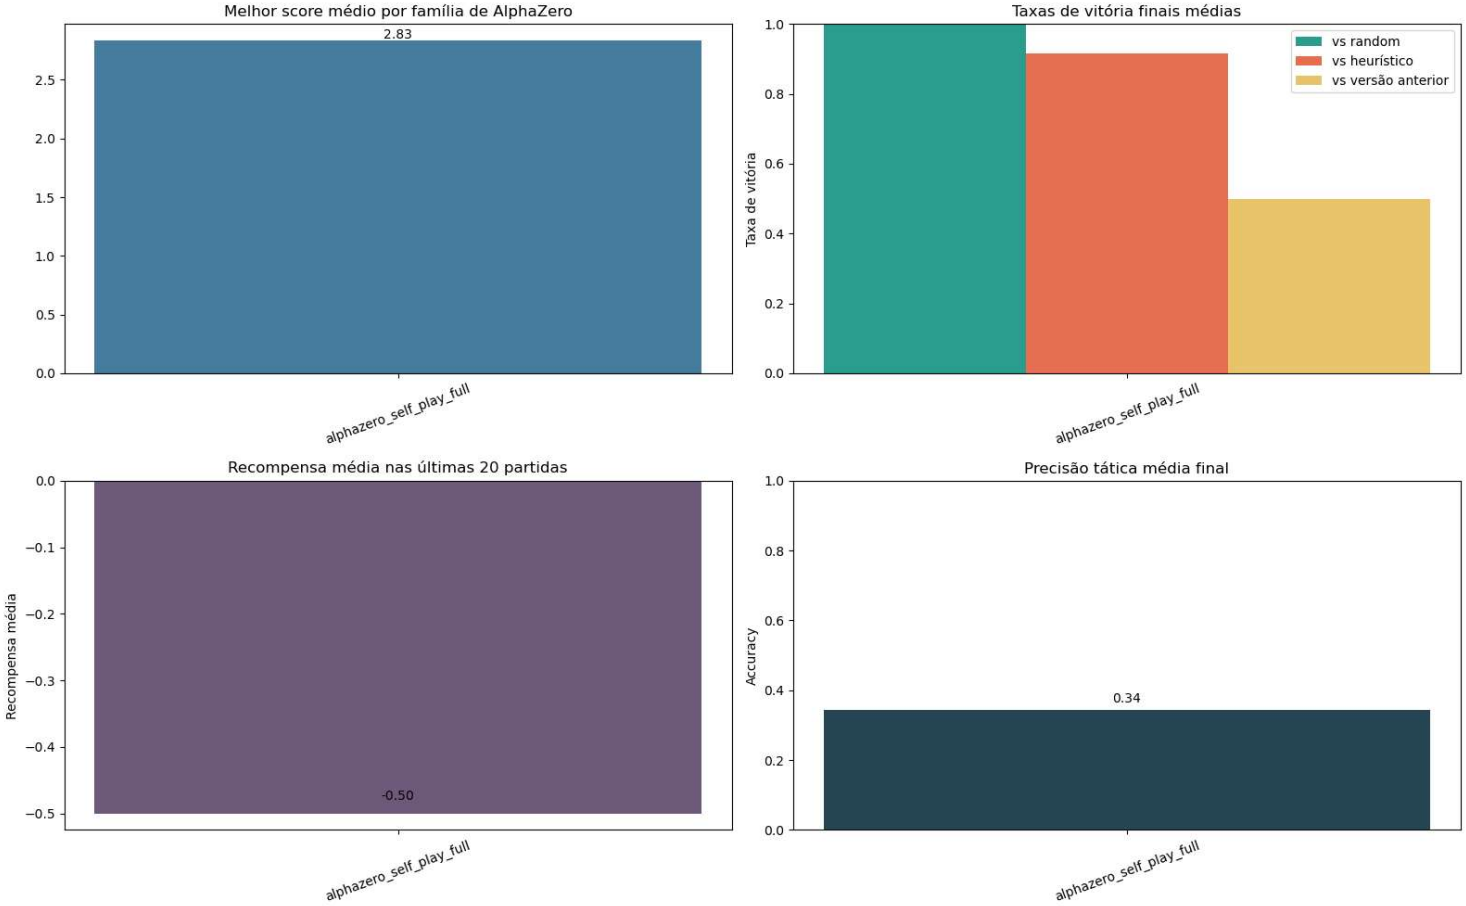

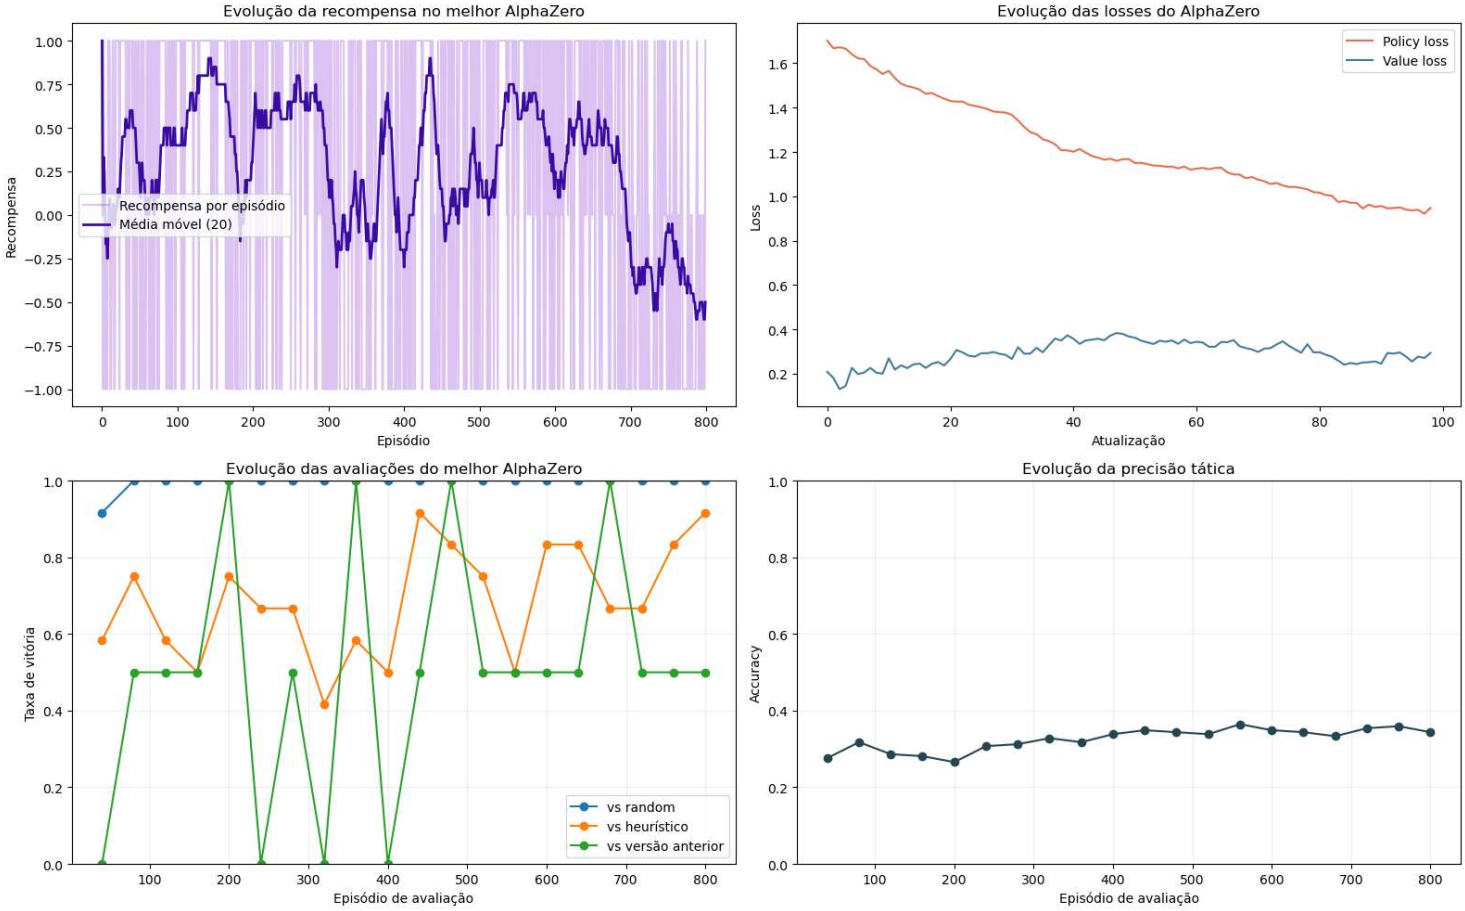

Resultados da execução em 12/05/2025

Treino do AlphaZero: 59m

As alterações ao mcts_simulations (64 -> 48), mcts_start_search_iter (16 -> 12) e mcts_max_search_iter (64 -> 48) não deram melhores resultados. Reverter!

```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42',
 'training_profile': 'full',
 'episodes': 800,
 'learning_rate': 0.0005,
 'batch_size': 256,
 'mcts_simulations': 48,
 'mcts_start_search_iter': 12,
 'mcts_max_search_iter': 48,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.0,
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 4}

{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 2.75,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 0.75,
  'mean_last_vs_previous': 0.0,
  'mean_reward_last_20': -0.05,
```

'mean_last_tactical_accuracy': 0.2604166666666667}}

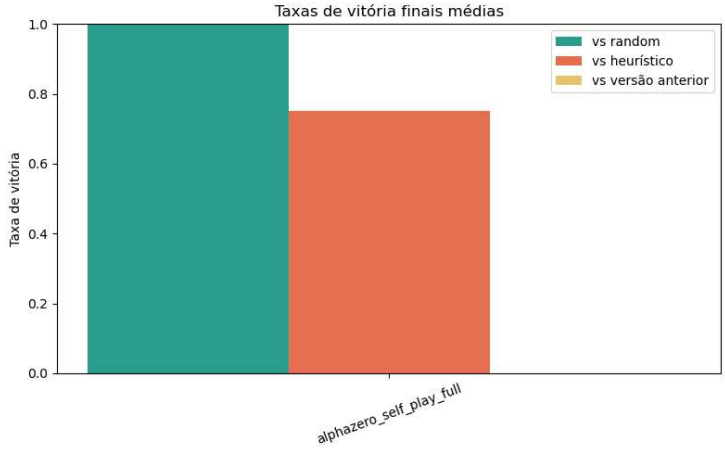

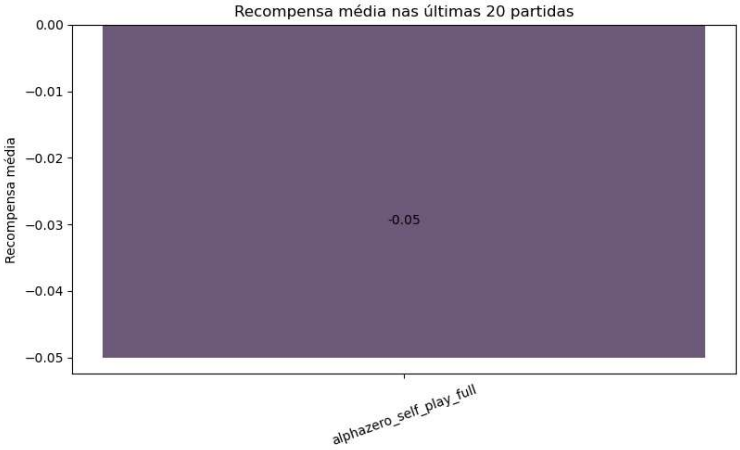

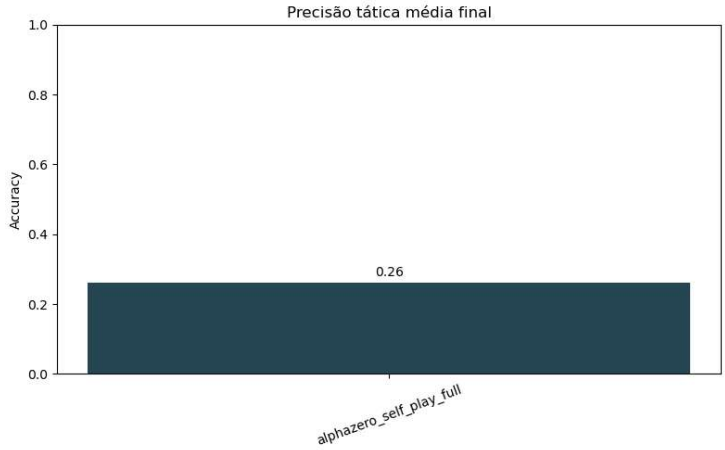

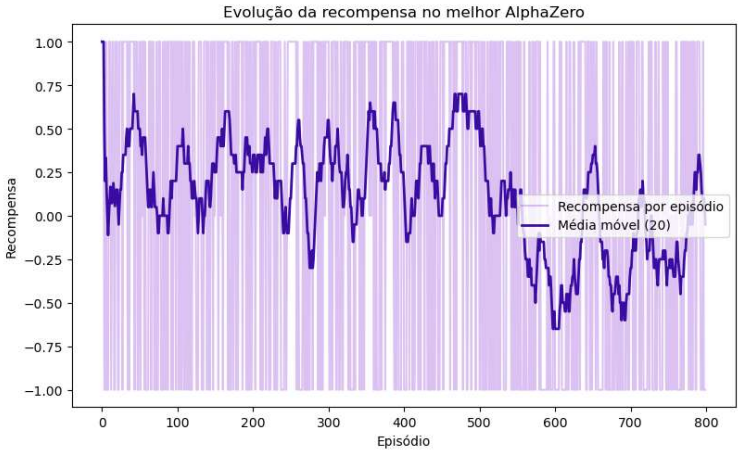

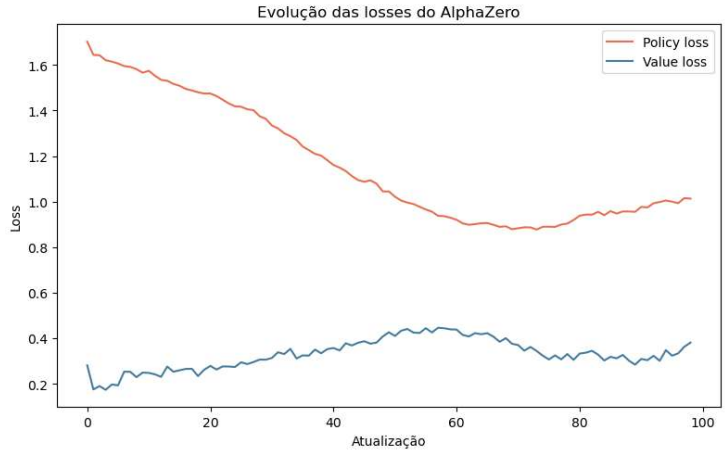

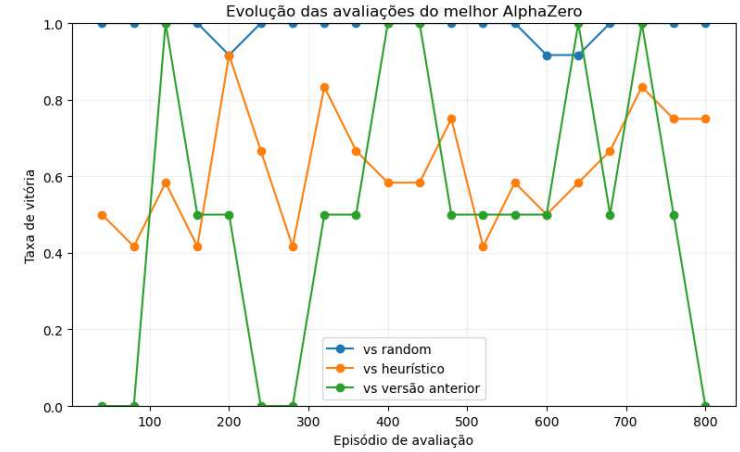

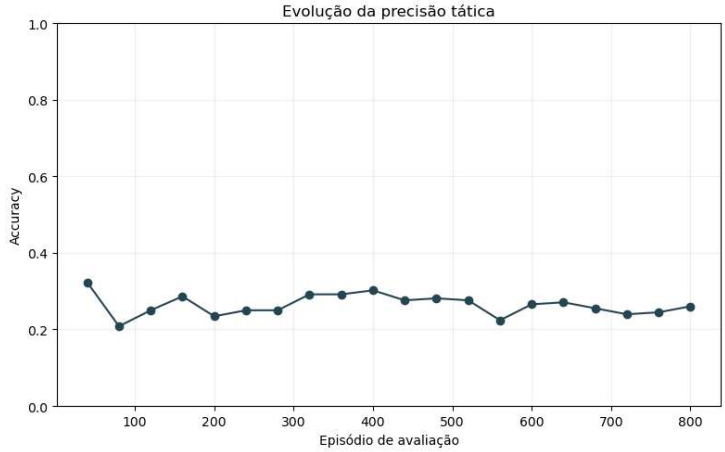

Resultados da execução em 12/05/2025

Treino do AlphaZero: 2h3m

Após análise da accuracy tática baixa (0.26), foram aplicadas as seguintes alterações para **melhorar o aprendizado de padrões táticos**:

Parâmetro	Anterior	Novo	Justificação
updates_per_episode	2	6	3× mais épocas de refinamento por episódio → melhor convergência tática
mcts_simulations	64	96	50% mais simulações MCTS → targets de melhor qualidade
temperature	1.25	1.0	Menos aleatoriedade → play mais greedy favorece aprendizado de padrões
temperature_drop_move	8	6	Transição mais rápida para greedy → menos exploração, mais exploração de boas jogadas
episodes_per_batch	1	1	Mantém feedback rápido após cada episódio
replay_capacity	20000	20000	Mantém memória de experiência generosa

Objetivo: Aumentar accuracy tática de 0.26 para **>0.40** através de:

1. **Mais atualizações** → convergência mais rápida
2. **MCTS mais forte** → targets mais confiáveis para a rede aprender
3. **Play menos aleatório** → agente identifica e replica padrões táticos com consistência

`Com a configuração acima, o computador encravou…`

Reconfigurei para:
updates_per_episode: 4
batch_size: 128
learning_rate: 0.0001
mcts_simulations: 64
temperature: 1.25

Parâmetro	Anterior	Novo	Impacto
`updates_per_episode`	6	4	33% menos atualizações → menos gradientes explosivos
`batch_size`	256	128	Metade do tamanho → menos memória, gradientes mais estáveis
`learning_rate`	0.0005	0.0001	5× mais pequeno → atualizações mais cautelosas
`mcts_simulations`	96	64	Menos exploração → targets ainda decentes
`temperature`	1.0	1.25	

```
{'run_name': 'alphazero_self_play_full_seed_42',
 'checkpoint_dir':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42',
 'training_profile': 'full',
 'episodes': 1600,
 'learning_rate': 0.0001,
 'batch_size': 128,
 'mcts_simulations': 64,
 'mcts_start_search_iter': 16,
```

```
 'mcts_max_search_iter': 64,
 'mcts_search_increment': 1,
 'eval_mcts_simulations': 80,
 'n_filters': 64,
 'n_res_blocks': 4,
 'temperature': 1.25,
 'dirichlet_alpha': 1.0,
 'dirichlet_epsilon': 0.15,
 'updates_per_episode': 4}


[PROGRESS] episode=1600/1600 | elapsed=7494.5s | 12.81 ep/min
[TIMING] episode=1600/1600 | elapsed=7494.5s | avg=4.68s/ep | 12.81 ep/min | GPU
mem=0.02GB
[LOOP-END] Batch 1600 finished, moving to next batch
{'episodes': 1600, 'best_score': 3.0, 'last_eval': {'episode': 1600.0,
'vs_random_win_rate': 1.0, 'vs_heuristic_win_rate': 1.0, 'vs_previous_win_rate':
0.5}, 'last_tactical_accuracy': {'episode': 1600.0, 'accuracy': 0.28125},
'best_checkpoint_path':
'/home/pcabrita/MIA/AR/TP/AR/notebooks/alphazero/outputs/alphazero_self_play_full
_seed_42/alphazero_best.pt'}

{'alphazero_self_play_full': {'num_runs': 1,
  'mean_best_score': 3.0,
  'mean_last_vs_random': 1.0,
  'mean_last_vs_heuristic': 1.0,
  'mean_last_vs_previous': 0.5,
  'mean_reward_last_20': 0.15,
  'mean_last_tactical_accuracy': 0.28125}}
```

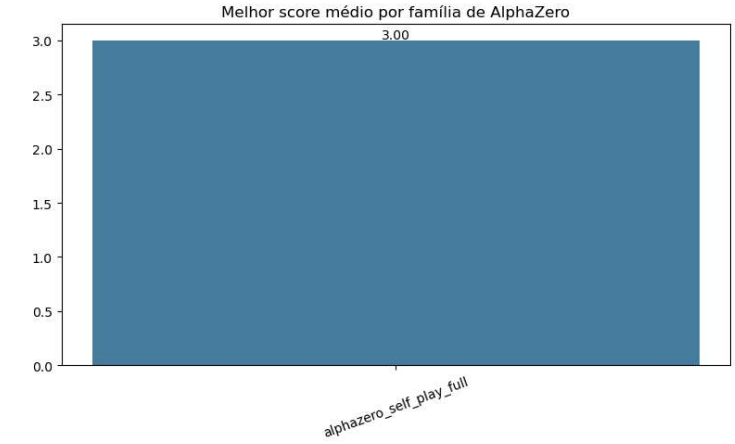

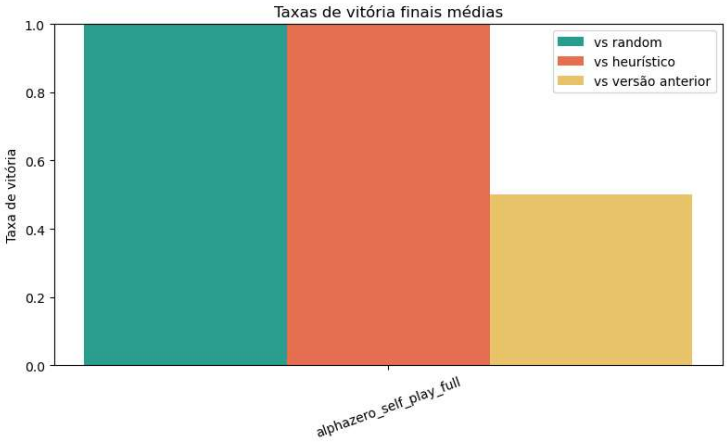

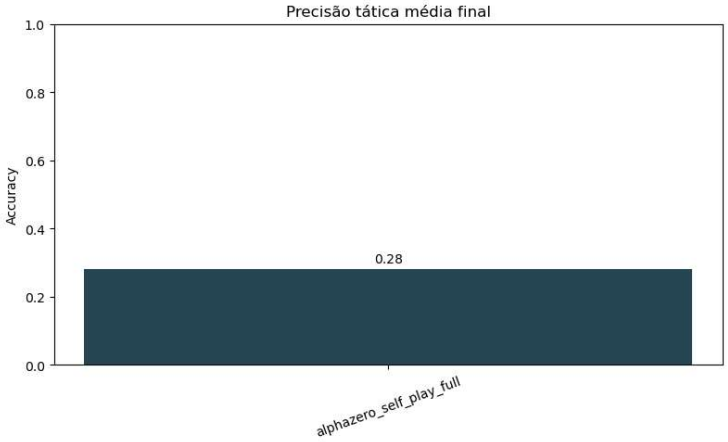

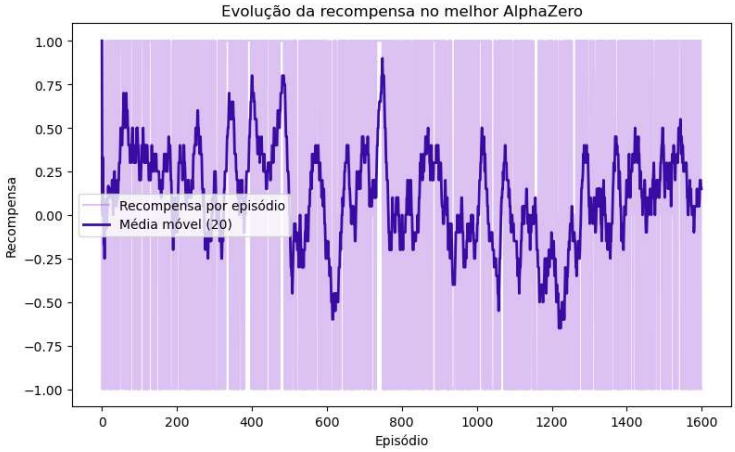
Evolução da recompensa no melhor AlphaZero
Recompensa por episódio
Média móvel (20)
Recompensa
Episódio

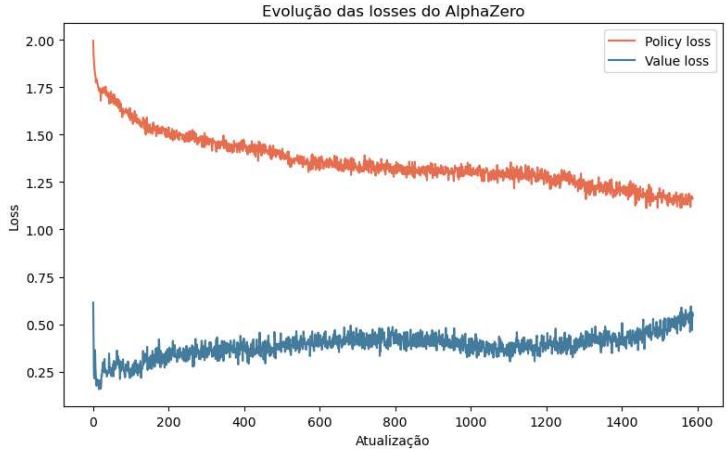
Evolução das losses do AlphaZero
Policy loss
Value loss
Loss
Atualização

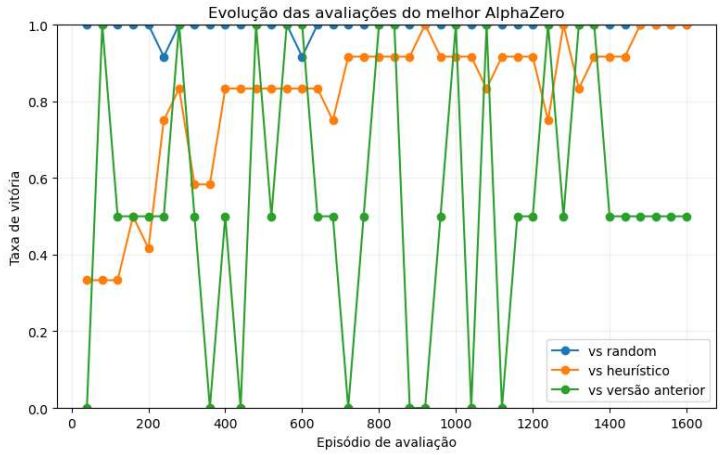
Evolução das avaliações do melhor AlphaZero
vs random
vs heurístico
vs versão anterior
Taxa de vitória
Episódio de avaliação

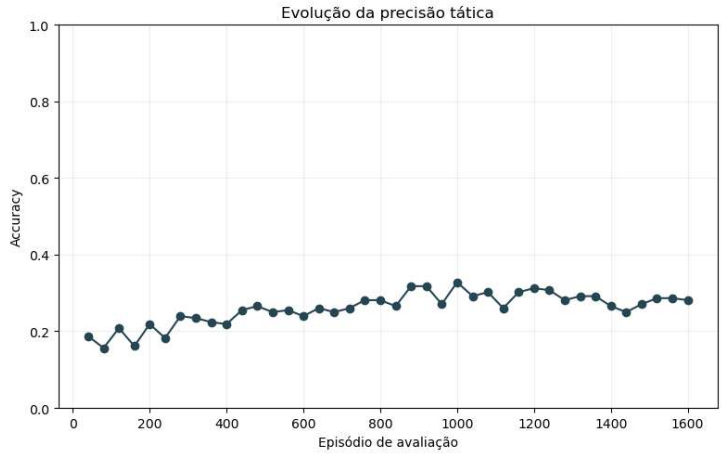
Evolução da precisão tática
Accuracy
Episódio de avaliação